

专业技能

- AI Agent 研发丰富经验：**作为公司内最早一批 Agent 开发者，熟练掌握 LangChain、LangGraph、Eino、ADK 等主流 Agent 框架；深入实践 ReAct、Function Call / MCP、Prompt Engineering、RAG 等核心技术；具备 Agent 后训练、Action Trace 回流、数据飞轮等持续优化的端到端落地经验；对 Transformer 与 GPU 架构有较深入的理解。
- 大型分布式系统高可用研发经验：**在流控、缓存、隔离、调度等方向有深入实践，能够端到端负责服务的稳定性与高可用建设；熟悉 Kubernetes 生态及常用运维工具（kubectI、tcpdump、gdb 等）。
- 有扎实的开发基本功和AI Coding能力：**熟练使用各类 AI Coding 工具（如 Claude Code、Codex 等）及主流 IDE，并形成了一套AI Coding方法论，在部门分享并在公司内推广。熟练掌握Golang、Python、C/C++开发语言，有扎实的数据结构和算法基础。
- 对前沿技术持续热情：**长期跟踪业界 AI 发展动态，多次主导部门级技术分享，通过分享会孵化出多个 Agent 项目并落地。

工作经验

字节跳动

基础架构·后端开发工程师

2023/07 - 至今

（2025.2 - 至今）**Agent 小组负责人/方向POC：**主导多个 Agent 项目的需求分析、方案设计与研发落地，带领小组取得显著业务收益。与此同时，探索出一套持续迭代优化的工作流程。代表性项目：

- 告警诊断 Agent**——面向 EB 级分布式存储服务，设计并实现问题快速定位的运维 Agent，**将告警诊断时长从 10 分钟以上缩短至 3 分钟以内(p99)，准确率超过 95%**；作为公司内最早发布的 AIOps Agent 之一，相关研发范式被多个兄弟部门复用。
- TOS 智能助理 Agent**——基于 Text2SQL + RAG + 内部知识库 + 日志系统 + 基础信息查询系统，构建 TOS 业务实时分析 Agent，覆盖**日志分析、疑难问题定位、运营数据统计**等场景；作为公司内最早发布的日志分析类 Agent 之一，研发范式被多个兄弟部门复用，**被评为“2025 存储团队最好用的工具”**。

（2023.7 - 2025.2）**稳定性组核心成员：**为大型分布式服务设计并落地多个稳定性核心组件与特性，覆盖流控、缓存、隔离、调度、降级等关键稳定性保障手段，将因流量失控导致的故障数由一年4~6次收敛到0~1次，显著提升服务稳定性与高可用性能。

- 流控业务算法：**使用令牌桶思想，落地了贴近业务的分布式流控算法。
- 稳定性手段：**设计并实现了业务分组调度、镜像流量灰度、Server侧配额缓存、流控3级降级等稳定性关键手段。

字节跳动

GPU池化计算·后端开发实习

2022/04 - 2022/09

参与 GPU 池化计算系统研发，面向 NVIDIA 多型号显卡实现异构算力的池化、隔离与流控；独立负责**流控模块**的设计与落地，保障多任务共享 GPU 时的算力稳定性。

教育经历

- **论文：**使用transformer架构，在基于视频的姿态估计方向，**算法效果达到SOTA（2022~2023）**—— 王雁林.基于视频的人体姿态估计方法优化研究[D].四川大学,2023.DOI:10.27342/d.cnki.gscdu.2023.000626.

西南科技大学

计算机科学与技术 · 本科

2015/09 - 2019/06

- **比赛获奖：**百度之星开发者大赛（2018深度学习任务）全国第14名；蓝桥杯程序设计大赛四川省一等奖及全国三等奖；CCF CSP认证（排名全国前16%）；“中青杯”、“数创杯”等全国大学生数学建模竞赛全国二等奖、三等奖。
- **证书/荣誉：**CET6；国家励志奖学金；优秀毕业生.